

Instituto Nuevos Aires

# Trabajo Práctico N° 2

## Desarrollo de un sistema de Inteligencia Artificial para la predicción de abandono de clientes (Customer Churn)

| | |
|---|---|
| **Estudiante** | Lucas Pérez Amador |
| **Carrera** | Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial |
| **Materia** | Desarrollo de Sistemas de Inteligencia Artificial (2.° cuatrimestre 2026) |
| **Docente** | MSc. Ángel Daniel Fuentes S. |
| **Algoritmo** | Regresión Logística |
| **Dataset** | Telco Customer Churn (Kaggle) |
| **Fecha de entrega** | 30 de octubre de 2026 |

## 1. Objetivo

Predecir si un cliente de una empresa de telecomunicaciones abandonará la compañía (*Customer Churn*) a partir de su antigüedad, servicios contratados, tipo de contrato y facturación, e identificar qué características se relacionan con el abandono. Se construyó con Python y Scikit-learn un modelo de aprendizaje supervisado de clasificación.

## 2. Fuente de los datos

Dataset público **Telco Customer Churn** (Kaggle), archivo `Telco_Customer_Churn.csv` (descargado como `WA_Fn-UseC_-Telco-Customer-Churn.csv` y renombrado). Tiene 7.043 clientes y 21 columnas. La variable objetivo `Churn` indica si el cliente abandonó (1.869; 26,54 %) o permaneció (5.174; 73,46 %). Notebook: `TP2_Churn_Regresion_Logistica.ipynb`.

## 3. Algoritmo elegido: Regresión Logística

Se usó `make_pipeline(StandardScaler(), LogisticRegression(max_iter=1000))`, el mismo esquema trabajado en las clases 26 y 29. Se eligió porque:

- **Es un problema de clasificación binaria** (abandona / no abandona), que es lo que resuelve este algoritmo.
- **Calcula la probabilidad de abandono** de cada cliente, además de la clase, lo que permite priorizar acciones de retención.
- **Generaliza bien:** obtuvo la misma exactitud en entrenamiento y en prueba (79,84 %) y supera la línea base.

`StandardScaler` lleva las variables a la misma escala (media 0, desvío 1) para que todas pesen igual. `max_iter=1000` es la cantidad máxima de iteraciones para encontrar los coeficientes. El umbral de decisión es 0,5.

## 4. Decisiones de preparación

- **Variables:** las 11 propuestas (`tenure`, `MonthlyCharges`, `TotalCharges`, `SeniorCitizen`, `Contract`, `InternetService`, `TechSupport`, `OnlineSecurity`, `PaymentMethod`, `Partner`, `Dependents`). En la exploración todas mostraron diferencias en el abandono; por ejemplo, 42,7 % con contrato mes a mes frente a 2,8 % con contrato de dos años. Se excluyó `customerID`, que es solo un identificador.
- **Valores faltantes:** `isnull().sum()` no mostraba nulos, pero `TotalCharges` venía como texto con 11 espacios en blanco, todos de clientes con `tenure = 0`. Se convirtió a número y se completaron con 0, su cargo acumulado real.
- **Categorías:** en `TechSupport` y `OnlineSecurity`, *No internet service* se unificó con *No*, porque ya lo indica `InternetService`.
- **Codificación:** las 7 variables categóricas se pasaron a columnas 0/1 con `pd.get_dummies(drop_first=True)`, quedando 15 columnas.
- **División:** 80 % entrenamiento (5.634 clientes) y 20 % prueba (1.409), con `stratify=y` para mantener la misma proporción de abandono en ambos conjuntos y `random_state=42`.

## 5. Resultados

El modelo acertó **1.125 de 1.409** clientes de prueba: **accuracy de 79,84 %**, 6,4 puntos por encima de predecir siempre "no abandona" (73,46 %). En entrenamiento la exactitud también es 79,84 %, así que no hay sobreajuste.

| Resultado en prueba | Clientes |
|---|---|
| Aciertos | 1.125 de 1.409 |
| Abandonos detectados | 203 de 374 |
| Abandonos no detectados (predijo que se quedaban) | 171 |
| Falsas alarmas (se quedaron y predijo abandono) | 113 |

Como solo el 26,5 % abandona, el accuracy no alcanza: el modelo detecta **203 de los 374** clientes que se fueron (54 %). Los **171 abandonos no detectados** son el error más costoso para la empresa. Por ejemplo, el registro 1639 abandonó y el modelo le dio una probabilidad de 0,45, apenas debajo del umbral de 0,5.

**Características asociadas al abandono.** La exploración muestra que abandonan más los clientes con contrato mes a mes (42,7 % frente a 2,8 % con contrato de dos años), fibra óptica, sin soporte técnico ni seguridad en línea y que pagan con cheque electrónico. Además, quienes abandonan llevan menos tiempo en la empresa y pagan más por mes.

## 6. Conclusiones

La Regresión Logística cumple el objetivo: clasifica bien a 8 de cada 10 clientes nuevos. Según la exploración, el perfil de mayor riesgo es: **cliente nuevo, con contrato mes a mes, fibra óptica, sin soporte técnico ni seguridad en línea y que paga con cheque electrónico**. Su principal debilidad es que deja sin detectar casi la mitad de los abandonos.

**Limitaciones:**

- Clases desbalanceadas (26,5 % abandona): el accuracy sobrestima el desempeño en quienes se van.
- `tenure` y `TotalCharges` están muy relacionadas, porque el cargo acumulado depende de la antigüedad.
- El modelo solo capta relaciones lineales y faltan datos como satisfacción o reclamos.
- Se evaluó con una sola división 80/20.

**Recomendación:** usar la probabilidad del modelo para priorizar la retención de clientes con contrato mes a mes y poca antigüedad, por ejemplo ofreciendo pasar a contratos anuales o sumar soporte técnico.